

作业感受

1. 简述下你是如何完成第一次挑战的。(例如, 如何使用 AI、如何工作迭代等方面)

答:全程使用豆包辅助操作。

- (1) 首先在终端粘贴豆包给的指令, 直接下载了 Ubuntu22.04;然后按照豆包指导的操作, 打开 Ubuntu,完成一系列的初始化操作, 开两个终端用来配置 SGLang 和 Ray 两个环境;
- (2) 接着往 SGLang 里面装 Qwen3 模型,按照豆包的要求进行 HF 镜像加速模型下载, 发现由于 huggingface 的 XET 协议导致国内镜像访问 xethub.hf.co 时会触发 201 认证报错, 镜像下载不稳定, 转向从 ModelScope(阿里)直接下载 Qwen3; 由于电脑没有 GPU,只能用 CPU, 所以需要关闭和修改 GPU 专用的一些功能。然后配置 Ray 环境, 启动 Ray head 集群, 由于没有 GPU,我创建 Ray 只能作为一个客户端发起请求而被 SGLang 用来提交任务和创建推理; 后根据豆包指导的指令启动 SGLang 服务, 报出“The server is fired up and ready to roll”, 启动成功。这样,SGLang 就成为了一个独立的 HTTP 服务器,可以通过 SGLang 对外的 HTTP 端口用调用 SGLang,环境部署完成。
- (3) 在 Ray 环境中向 SGLang 发起请求, 成功; 输入豆包给的指令从 Mooncake 官方轨迹文件用 head 获取前 20 条, 新建文件把豆包给的能够满足题目的测试脚本粘贴进去, 运行, 就可以向 SGLang 发出 20 条请求了。

2. 你觉得哪部分工作最困难, 你是如何克服这个困难的。

答:因为之前都没怎么接触过 Linux 系统, 配置环境对我来说是最难的, 各种指令看不懂, 按照豆包做的同时学几下, 才勉强明白一些指令是干嘛用的, 但也只是这样了。至于做挑战任务环节, 感觉最让人发麻的还是那个测试脚本, 如果不是豆包给的, 没学过 python 也根本不会, 甚至后面还发现它给的原本还测不了 TTFT,后面再要求改的。现在才意识到, 大模型里都是 python,本学期课程昇腾程序设计里要求我们在华为的开发板上部署大模型也是这样手忙脚乱的, 看不懂。后面还得看看, 大一有 C 和 C++基础, 应该能很快补上 python 的基础语法吧?

3. 你觉得类似的从 0 到 1 的科研工作, 需要包含哪些方面的研究, 对你今后的科研工作有什么启发

答:我认为, 这些从 0 到 1 的科研工作, 需要阅读相关论文, 构建与完善相应方面的知识体系, 且还需要多多实验, 学习与实践并行才能不断完善方案, 提出改进实验的思路。就像我用豆包辅助我做这次挑战一样, 如果不是在按照豆包的指导执行过程中不

断发问，了解为什么它要这么干，以及不停地遇到各种问题，我就不可能发现豆包给出方法所存在的问题，就会一直顺着豆包的方法困在死胡同里。